



Terminologias e Conceitos em Sequenciamento de Exoma.



ÍNDICE

1.  Conceitos Fundamentais de Genômica
2.  Terminologia de Sequenciamento NGS
3.  Processamento Bioinformático
4.  Análise de Variantes
5.  Interpretação Clínica
6.  Controle de Qualidade
7.  Conceitos Específicos de Exoma
8.  Anotação e Bases de Dados
9.  Ferramentas de Análise
10.  Genomas de Referência
11.  Estrutura e Interpretação de Arquivo VCF
12.  Tipos de Variantes e Classificação Funcional
13.  Limitações do WES



1. CONCEITOS FUNDAMENTAIS DE GENÔMICA



Genoma

Definição: Conjunto completo de material genético (DNA) de um organismo, incluindo todos os genes, sequências regulatórias e DNA não-codificante.

Contexto: O genoma humano contém ~3 bilhões de pares de bases distribuídos em 46 cromossomos.



Exoma

Definição: Porção do genoma composta por todas as regiões que codificam proteínas.

Proporção: Representa ~1-2% do genoma total (~30-60 Mb, a depender do kit de captura).

Importância: Concentra aproximadamente **85% das variantes causais em doenças mendelianas conhecidas**, embora o número atual de genes codificantes de proteína seja ~19.500 (GENCODE v45, 2024), menor do que estimativas históricas de 20.000-25.000.



Éxon (Exon)

Definição: Sequência de DNA que é transcrita e traduzida em proteína.

Características:

- Codificam informações para síntese proteica
- Múltiplos éxons são conectados após remoção de íntrons
- Representam ~1-2% do genoma

 Íntron (Intron)

Definição: Sequência de DNA dentro de um gene que é transcrita em RNA, mas removida durante processamento.

Características:

- Não codificam proteína
- Removidos antes da tradução (splicing)
- Representam a maioria do gene
- Regiões flangeadoras (± 10 pb) são captadas pela maioria dos kits WES — sítios de splicing canônicos

 Gene

Definição: Unidade funcional hereditária composta por:

- Sequências codificantes (**éxons**)
- Sequências não-codificantes (**íntrons**, regiões regulatórias)

Função: Codifica uma proteína ou RNA funcional responsável por características hereditárias.

 UTR (Untranslated Region)

Definição: Regiões do RNA mensageiro **não traduzidas** em proteína, mas funcionalmente importantes.

Tipo	Função
5' UTR	Regulação da tradução, localização de sequências
3' UTR	Poliadenilação, estabilidade do mRNA, ligação de microRNAs

 Cromossomo

Definição: Estrutura microscópica contendo DNA condensado em cromatina.

Composição Humana: 46 cromossomos (23 pares)

- 22 pares autossômicos
- 1 par de cromossomos sexuais (XX ou XY)

 Nucleotídeo

Definição: Unidade básica do DNA, composto por:

- Base nitrogenada (A, T, G, C)
- Açúcar desoxirribose

- Grupo fosfato

Sequência: Nucleotídeos ligam-se para formar a dupla hélice do DNA.



Base Nitrogenada

Purinas (estrutura dupla):

- Adenina (A)
- Guanina (G)

Pirimidinas (estrutura simples):

- Timina (T)
- Citosina (C)



2. TERMINOLOGIA DE SEQUENCIAMENTO NGS



NGS (Next-Generation Sequencing)

Definição: Tecnologia de sequenciamento em larga escala que permite ler milhões/bilhões de fragmentos de DNA simultaneamente.

Plataformas dominantes: Illumina (NovaSeq 6000, NovaSeq X Plus, NextSeq 2000) para leitura curta; PacBio HiFi e Oxford Nanopore para leitura longa.



WES (Whole Exome Sequencing)

Definição: Sequenciamento de todas as regiões codificantes do genoma.

Escopo: Captura ~19.500 genes codificantes de proteína

Aplicação: Ideal para diagnóstico de doenças mendelianas raras



WGS (Whole Genome Sequencing)

Definição: Sequenciamento do genoma **completo**.

Escopo: Inclui:

- Regiões codificantes
- Regiões não-codificantes
- Íntrons
- Regiões intergênicas

Aplicação: Pesquisa avançada, detecção de variantes estruturais, casos onde WES foi negativo.



Panel Sequencing (Painel Genético)

Definição: Sequenciamento direcionado de um **subconjunto específico** de genes.

Características:

- Associados a doença específica
- Cobertura ultra-profunda

- Custo-efetivo para diagnóstico direcionado



Targeted Sequencing

Definição: Sequenciamento focado em **regiões específicas** de interesse.

Características:

- Cobertura alta e profunda
- Maior eficiência do que WGS/WES
- Ideal para validação de achados



Biblioteca (Library)

Definição: Preparação de fragmentos de DNA com adaptadores ligados, pronta para sequenciamento.

Processo: Preparação técnica crucial que afeta qualidade dos resultados.



Fragmento (Fragment)

Definição: Pedaco de DNA extraído e preparado para sequenciamento.

Tamanho Típico: 100-500 pares de bases (pb)



Read (Leitura)

Definição: Sequência de DNA lida pelo sequenciador durante um ciclo de sequenciamento.

Tipos:

- **Single-end:** Sequência de uma única extremidade do fragmento
- **Paired-end:** Sequências de ambas as extremidades (preferido em WES)



Paired-End Sequencing

Definição: Leitura de **ambas as extremidades** de um fragmento.

Vantagens:

- Informações sobre tamanho do insert
- Maior precisão do alinhamento
- Melhor detecção de indels



Read Length

Definição: Comprimento total da sequência lida pelo sequenciador.

Exemplos: 75 bp, 100 bp, 150 bp, 250 bp, **300 bp** (NovaSeq X Plus, 2023)



Throughput

Definição: Quantidade total de sequências produzidas em um experimento.

Medida: Gigabases (Gb) ou Terabases (Tb). WES clínico típico: 6-15 Gb/amostra.



Insert Size

Definição: Distância entre o final de um read forward e o início do read reverse em sequenciamento paired-end.

Tamanho típico: 200-400 pb

Importância: Informação crítica para alinhamento e detecção de indels e variantes estruturais.



Cobertura (Coverage / Depth)

Definição: Número médio de vezes que cada posição do genoma é sequenciada.

Nível	Profundidade	Aplicação
Profunda	>100×	Deteção de variantes raras, mosaicismos
Moderada	30-50×	Diagnóstico clínico padrão
Baixa	<10×	Insuficiente para chamada confiável



Cobertura Uniforme

Definição: Distribuição **consistente** de reads ao longo da região alvo.

Importância: Evita hotspots com super-cobertura e vazios com sub-cobertura.

Desafio: Regiões GC-ricas (>65% GC) e sequências repetitivas concentram a maioria dos falsos negativos.



3. PROCESSAMENTO BIOINFORMÁTICO



Sequência FASTQ

Formato: Arquivo de sequências **brutas** com scores de qualidade.

Componentes:

- Identificador da sequência
- Sequência de nucleotídeos
- Identificador opcional
- Scores de qualidade Phred (Q20, Q30, etc.)

Tamanho: Centenas de Gb por experimento típico.



Alinhamento (Alignment)

Definição: Processo de **mapear reads** sequenciados para uma sequência de referência.

Referência Padrão: hg38 (GRCh38) - genoma humano de referência atual

Ferramentas padrão: BWA-MEM (v0.7.19, Li & Durbin 2009); BWA-MEM2 (2× mais rápido, saída idêntica); DRAGEN-BWA (implementação Illumina em FPGA).

Nota crítica: Configurar **Read Group (@RG)** é essencial — sem SM/LB/PL, MarkDuplicates e chamadores de variante podem falhar silenciosamente.



BAM (Binary Alignment Map)

Formato: Binário e comprimido (arquivo de alinhamento).

Conteúdo:

- Reads alinhados
- Posição genômica
- Scores de qualidade
- CIGAR strings
- Metadados adicionais (@RG)

Tamanho: ~1/4 do FASTQ original. Deve ser indexado (`samtools index`).



SAM (Sequence Alignment Map)

Formato: Versão textual legível do arquivo BAM.

Uso: Para inspeção e debugging (raramente armazenado).



CRAM

Formato: Sucessor do BAM, com compressão ~40% mais eficiente.

Uso: Adotado por grandes consórcios (gnomAD, UK Biobank). Requer o mesmo FASTA de referência para descompressão.



CIGAR String

Definição: Compact Idiosyncratic Gapped Alignment Report.

Função: Descreve como reads estão alinhados à referência.

Código	Significado
M	Match/Mismatch (alinhamento)
=	Match exato
X	Mismatch (substituição)
I	Insertion (no read)
D	Deletion (no read)
N	Skipped region (no genoma)
S	Soft clipping
H	Hard clipping
P	Padding



Quality Score (Phred Score)

Definição: Medida da confiabilidade de uma base chamada em sequenciamento. Escala logarítmica: $Q = -10 \cdot \log_{10}(P)$, P = probabilidade de erro.

Score	Acurácia	Erro
Q20	99%	1%
Q30	99,9%	0,1%
Q40	99,99%	0,01%

Alvo WES clínico: ≥80% das bases com Q≥30.



GATK (Genome Analysis Toolkit)

Definição: Suite completa de ferramentas para processamento de dados de sequenciamento (versão atual: v4.6).

Componentes principais:

- **MarkDuplicates:** Identifica reads derivados de mesma molécula (PCR duplicates)
- **BaseRecalibrator (BQSR):** Recalibração de scores de qualidade
- **HaplotypeCaller:** Chamada de variantes germinais (padrão-ouro)
- **MuTect2:** Chamada de variantes somáticas



Variant Calling

Definição: Processo de **identificar variantes genéticas** comparando reads com sequência de referência.

Objetivo: Encontrar diferenças entre sequência do paciente e referência.



Caller de Variantes

Ferramenta	Especialidade	Vantagem
GATK HaplotypeCaller (v4.6)	Variantes germinais	Padrão-ouro, robusto
DeepVariant (v1.6, Google)	Rede neural convolucional	Alta precisão; usado por Illumina DRAGEN
FreeBayes (v1.3.10)	Bayesiano, haplótipo	Flexível; padrão no Galaxy
Strelka2 (v2.9)	Modelo Illumina	Alta precisão em indels
bcftools call (v1.20)	Bayesiano posicional	Simples e rápido
MuTect2	Variantes somáticas	Específico para tumor



4. ANÁLISE DE VARIANTES



Variante Genética (ou Mutação)

Definição: Qualquer alteração na sequência de nucleotídeos (A, C, T, G) em relação ao genoma de referência.

Contexto: Base para toda interpretação clínica.



SNV (Single Nucleotide Variant)

Definição: Variante em que um **único nucleotídeo** é alterado, **independentemente da frequência populacional**.

Exemplo: GATC → GGTC (A→G em posição 2)

Frequência: ~4-5 milhões de SNVs por genoma humano.

! SNP (Single Nucleotide Polymorphism)

Definição: Por definição clássica, um SNV com **MAF** $\geq 1\%$ na população.

Distinção importante: Uma variante rara ou de novo **NUNCA** deve ser chamada de **SNP** — o termo correto é SNV. Em WES clínico, a maioria das variantes de interesse é SNV rara, não SNP.

+— Indel (Insertion-Deletion)

Definição: Pequenas **inserções ou deleções** de um ou mais pares de bases (≤ 50 pb).

Tipos:

- **In-frame:** Múltiplo de 3 pb (mantém quadro de leitura)
- **Frameshift:** Altera quadro de leitura → proteína truncada (geralmente patogênica)

Impacto: Frameshift indels são usualmente candidatos ao critério **PVS1** em genes com mecanismo LOF conhecido.

🎲 MNV (Multi-Nucleotide Variant)

Definição: Múltiplas substituições nucleotídicas em posições adjacentes.

Nota: Menos comum que SNVs. Clinicamente relevante quando ocorre dentro do mesmo códon (pode alterar o efeito predito).

📊 CNV (Copy Number Variation)

Definição: Variação no **número de cópias** de um segmento de DNA.

Tamanho: >1 Kb (deleções, duplicações)

Deteção em WES: Possível com sensibilidade limitada, usando ferramentas específicas (**ExomeDepth**, **XHMM**, **CNVkit**, **GATK gCNV**). aCGH, MLPA ou WGS oferecem maior precisão.

🌀 SV (Structural Variant)

Definição: Variação estrutural **grande** (>1 Kb).

Tipos:

- Translocações
- Inversões
- CNVs complexas

Deteção: Melhor por WGS ou sequenciamento de leitura longa (PacBio, Nanopore).

🔄 Repeat Expansion

Definição: Expansão patogênica de **sequências repetidas**.

Exemplos clínicos:

- Huntington: HTT (CAG repeats)
- Síndrome do X Frágil: FMR1 (CGG repeats)
- Ataxia Friedreich: FXN (GAA repeats)

Nota: WES não detecta expansões de repeats. Requer teste específico (PCR triplet-primed, ExpansionHunter em WGS, sequenciamento longo).



VCF (Variant Call Format)

Definição: Formato padrão para armazenar variantes genéticas.

Conteúdo:

- Posição genômica
- Genótipo
- Qualidade da chamada
- Anotações funcionais

Uso: Padrão industrial para intercâmbio de dados genômicos.



Genótipo (Genotype)

Definição: Composição alélica de um indivíduo em um locus específico.

Tipo	Descrição	Exemplo
Homozigoto	Dois alelos idênticos	AA ou aa
Heterozigoto	Dois alelos diferentes	Aa
Hemizigoto	Um único alelo	Homens em cromossomo X
Composto heterozigoto	Dois alelos distintos afetados no mesmo gene	Comum em recessivas



Frequência Alélica (Allele Frequency)

Definição: Proporção de um alelo específico em uma população.

Expressão: Percentual ou frequência relativa (0-1)

Importância: Distinguir variantes raras vs. comuns.



MAF (Minor Allele Frequency)

Definição: Frequência do **alelo menos comum** em uma população.

Aplicação Clínica:

- MAF <1% → Variante rara (potencialmente patogênica)
- MAF ≥5% → Variante comum (critério **BA1** stand-alone benigno)



Variante Rara

Definição: Variante com **MAF <1%** na população.

Associação: Frequentemente associada a doenças mendelianas.

Importância: Maior probabilidade de patogenicidade. Ausência em gnomAD sustenta o critério PM2_Supporting.



Variante Benigna

Definição: Variante **sem impacto clínico** significativo.

Características:

- MAF elevado (>5%)
- Codificante sinônima sem impacto em splicing
- Sem predição de dano em preditores calibrados

? **VUS (Variant of Uncertain Significance)**

Definição: Variante cuja **significância clínica não pode ser determinada** com confiança.

Frequência: ~25-50% de variantes encontradas em WES

Ação: Requer estudos adicionais (segregação familiar, estudos funcionais). **Reclassificação periódica é essencial** — 5-10% de VUS são reclassificáveis a cada 2-3 anos.



Filtro (Filter)

Definição: Indicador em arquivo VCF mostrando se variante passou critérios de qualidade.

Status	Significado
PASS	Passou em todos filtros
FAIL/LowQual	Falhou em pelo menos 1 filtro



5. INTERPRETAÇÃO CLÍNICA



ACMG/AMP (American College of Medical Genetics and Genomics)

Definição: Critérios padronizados para classificação de variantes germinativas (Richards et al., Genet Med, 2015). Baseados na combinação de **28 critérios de evidência**.

5 Categorias:

Categoria	Definição	Ação Clínica
Patogênica (P)	Causa doença (certeza alta)	Reportar
Provavelmente Patogênica (LP)	Causa doença (probabilidade >90%)	Reportar
VUS	Significância incerta	Investigar; não usar em decisão clínica
Provavelmente Benigna (LB)	Não causa doença	Não reportar
Benigna (B)	Não causa doença (certeza alta)	Não reportar



Critérios de Patogenicidade

Nível	Códigos	O que evocam
Very Strong	PVS1	Loss-of-function em gene cujo mecanismo LOF causa doença
Strong	PS1-PS4	PS1: mesmo aa já P; PS2: de novo confirmado; PS3: estudo funcional; PS4: prevalência casos vs.

		controles
Moderate	PM1-PM6	PM1: hotspot; PM2: ausente/rara em gnomAD; PM3: em trans com P/LP; PM4: alteração de comprimento; PM5: novo missense no mesmo aa; PM6: de novo assumido
Supporting	PP1-PP5	PP1: co-segregação; PP2: gene intolerante a missense; PP3: preditores in silico; PP4: fenótipo específico; PP5: fonte confiável



Critérios de Benignidade

Nível	Códigos	O que evocam
Stand-alone	BA1	MAF $\geq 5\%$ em subpopulação gnomAD com N adequado
Strong	BS1-BS4	BS1: MAF > esperado; BS2: em homozigose em adulto saudável; BS3: estudo funcional benigno; BS4: falta de co-segregação
Supporting	BP1-BP7	BP1: missense em gene LOF-only; BP2-BP6: variados; BP7: sinônima sem impacto em splicing



Refinamentos ClinGen SVI (2018-2023)

Contexto: Desde 2018, o ClinGen Sequence Variant Interpretation vem publicando refinamentos das diretrizes ACMG que continuam vigentes hoje:

- Tavitgian et al., 2018 — Framework bayesiano de combinação de critérios
- Abou Tayoun et al., 2018 — Árvore de decisão do PVS1 (modula PVS1, PVS1_Strong, PVS1_Moderate, PVS1_Supporting)
- Ghosh et al., 2018 — Revisão do critério BA1
- Biesecker et al., 2018 — Uso restrito de PP5/BP6
- Pejaver et al., 2022 — Calibração de PP3/BP4 para preditores in silico
- Walker et al., 2023 — Critérios de splicing usando SpliceAI



Pathogenicity Prediction — Preditores in silico

Definição: Ferramentas que predizem se variante é potencialmente prejudicial.

Preditores modernos calibrados (recomendação ClinGen):

Ferramenta	Escopo	Uso ACMG
REVEL	Missense (meta-preditor)	PP3 $\geq 0,644$; PP3_Strong $\geq 0,932$ (Pejaver 2022)
AlphaMissense	Missense (DeepMind 2023)	71M variantes cobertas; adoção crescente

SpliceAI	Splicing	PP3/BP4 splicing; $\Delta \geq 0,20$ sugere impacto (Walker 2023)
CADD	SNV + indel	Uso individual desencorajado; suporte quando outros indisponíveis
PolyPhen-2, SIFT, MutationTaster	Missense	** Uso isolado desencorajado ** — considerados obsoletos

Regra prática: Integrar múltiplos preditores; nunca decidir com base em um só. **Franklin** e **VarSome** implementam a calibração ClinGen internamente.



Segregação Familiar

Definição: Estudo de se uma variante **co-segrega** com afetados na família.

Suporta: Patogenicidade quando presente em todos afetados, ausente em não-afetados.

Valor: Evidência crítica para critérios **PP1** (Supporting) e **PS4/BS4** (Strong).



Penetrância (Penetrance)

Definição: Proporção de **portadores de genótipo** que manifestam fenótipo associado.

Exemplo: Gene com 80% penetrância → 80% dos portadores afetados, 20% não afetados.

Nota: Penetrância reduzida complica interpretação — ausência de fenótipo não é evidência definitiva de benignidade.



Expressividade

Definição: **Variação no grau e tipo** de manifestações clínicas de genótipo específico.

Exemplo: Distrofia muscular com expressividade variável (leve a severa).



Gene Candidato

Definição: Gene hipoteticamente associado a fenótipo/doença.

Baseado em:

- Função proteica
- Localização genômica
- Dados de literatura
- Ontologia HPO — correspondência fenótipo-gene



Fenótipo (Phenotype)

Definição: Conjunto **observável** de características clínicas e biológicas do indivíduo.

Importância: Essencial para interpretação de variantes. Codificação em **termos HPO** é padrão-ouro para descrição estruturada.



Herança Mendeliana e não-Mendeliana

Padrão	Características	Exemplo
--------	-----------------	---------

Autossômica Dominante	Uma cópia do alelo afetado causa doença	Huntington, Acondroplasia
Autossômica Recessiva	Duas cópias necessárias	Fibrose Cística, Talassemia
X-Ligada Dominante	Afeta homens e mulheres; homens mais graves	Síndrome de Rett
X-Ligada Recessiva	Afeta principalmente homens	Hemofilia A, Distrofia Duchenne
Mitocondrial	Herança materna exclusiva	MELAS, MERRF, Neuropatia de Leber
Imprinting	Expressão depende do progenitor de origem	Prader-Willi, Angelman
Oligogênica	Múltiplos genes contribuem	Retinite pigmentosa, Bardet-Biedl
De novo	Ausente em ambos os pais biológicos	Encefalopatias epiléticas precoces



6. CONTROLE DE QUALIDADE



QC (Quality Control)

Definição: Conjunto de métricas para garantir qualidade dos dados.

Inclui:

- Trimagem de sequências de baixa qualidade
- Remoção de adaptadores
- Verificação de contaminação
- Validação de cobertura



Adapter Trimming

Definição: Remoção de sequências de **adaptador** ligadas aos reads.

Importância: Adaptadores podem interferir em alinhamento e chamada de variantes.

Ferramentas modernas: **fastp** (mais rápida, QC integrado), Trimmomatic, cutadapt.



FastQC

Definição: Ferramenta de análise de qualidade de sequências FASTQ.

Relatórios:

- Distribuição de qualidade por posição
- Composição de bases
- Presença de adaptadores
- Sequências de baixa complexidade



MultiQC

Definição: Agregação de múltiplos relatórios QC em resumo visual único.

Vantagem: Visão integrada de qualidade para toda a corrida de sequenciamento — detecta outliers em minutos.



Sequência de Baixa Complexidade

Definição: Sequência com **repetições simples** ou composição base enviesada.

Exemplo: AAAAA, GCGCGC

Indicador: Possível artefato técnico ou contaminação.



PCR Duplicate

Definição: Reads derivados da **mesma molécula de DNA** através de amplificação PCR.

Ação: Devem ser **marcados** (não removidos — padrão moderno preserva reads).

Ferramenta: Picard MarkDuplicates ou GATK MarkDuplicates



Contaminação

Definição: Presença de DNA **não-intencional**.

Fontes:

- Contaminação microbiana
- Cruzamento entre amostras (cross-contamination)
- Contaminação ambiental

Deteção: Análise de composição alélica; ferramentas como VerifyBamID, somalier.



Métricas de Alinhamento

Métrica	Descrição	Mínimo Aceitável
Taxa de Mapeamento	% de reads alinhados ao genoma	>95%
Taxa de Duplicação	% de reads PCR duplicados	<20% (WES)
Inserção Média	Tamanho médio dos fragmentos	200-400 bp
On-target %	% reads em regiões alvo	>65% (WES)
Cobertura média no alvo	Coverage nas regiões codificantes	≥100×
% alvo a ≥20×	Fração de bases-alvo com cobertura suficiente	≥95%
Ti/Tv ratio	Razão transições/transversões (SNVs)	~3,0 (exoma)



7. CONCEITOS ESPECÍFICOS DE EXOMA



Região Alvo (Target Region)

Definição: Regiões de interesse no sequenciamento.

Inclui:

- Éxons (regiões codificantes)

- Regiões UTR próximas
- Regiões de splicing (± 10 pb dos íntrons flanqueadores)

Sonda (Probe)

Definição: Sequência de DNA **biotinilada** usada para captura.

Função: Hibridiza com fragmentos de DNA complementares durante preparação de biblioteca WES.

Captura por Hibridização

Método: Usa sondas biotiniladas para capturar fragmentos de interesse.

Processo:

- Fragmentação do DNA genômico
- Hibridização com sondas
- Captura por beads magnéticas
- Enriquecimento de regiões alvo

Kits comerciais comuns: Twist Exome, Agilent SureSelect, IDT xGen, Illumina TruSight One.

Captura por PCR

Método: Usa primers PCR para amplificar regiões específicas.

Vantagem: Maior especificidade que hibridização.

Desvantagem: Limitado a número pequeno de regiões.

Off-Target Reads

Definição: Reads que se alinham **fora** da região alvo definida.

Impacto: Reduz eficiência de sequenciamento e cobertura alvo.

On-Target Percentage

Definição: Proporção de reads mapeados dentro da região alvo.

Ideal WES: ≥ 65 -90% (depende do kit)

Fórmula: $(\text{Reads em regiões alvo} / \text{Total de reads}) \times 100$

Cobertura Alvo vs. Cobertura Média

Métrica	Definição
Cobertura Alvo	Coverage médio especificamente em regiões codificantes
Cobertura Média	Coverage em todo genoma ou região analisada

Importante: Monitorar ambas para QC completo.

Éxons Perdidos (Missing Exons)

Definição: Éxons com cobertura **insuficiente** ($< 20\times$) para chamada confiável.

Consequência: Falsos negativos (variantes não detectadas).

Solução: Validação por Sanger, MLPA ou análise complementar.



Regiões Difíceis de Sequenciar

Características:

- GC-ricas (>65% GC)
- Homopolímeros (AAAA, CCCC)
- Sequências repetitivas
- Pseudogenes (SMN1/SMN2, CYP21A2, HBA)

Desafio: Captura e sequenciamento impreciso → sub-cobertura → falsos negativos.



Normalização de Cobertura

Definição: Corrige variações em cobertura entre regiões ou amostras.

Objetivo: Análise comparativa acurada.

Métodos: GC-content correction, local regression, PCA.



8. ANOTAÇÃO E BASES DE DADOS



Anotação (Annotation)

Definição: Adiciona **informações funcionais** às variantes detectadas.

Inclui:

- Impacto funcional (missense, frameshift, etc.)
- Frequência populacional (gnomAD)
- Evidência clínica (ClinVar)
- Predição de patogenicidade (REVEL, AlphaMissense, SpliceAI)

Nota crítica: Normalizar VCF com `bcftools norm` **antes** de anotar. Sem normalização, variantes complexas ficam anotadas erroneamente.



VEP (Variant Effect Predictor)

Definição: Ferramenta de anotação funcional de variantes (Ensembl).

Prediz:

- Efeitos em genes
- Efeitos em transcritos
- Efeitos em proteínas



ANNOVAR

Definição: Software para anotação **rápida e funcional** de variantes.

Características:

- Anotação de múltiplas bases de dados
- Predição de impacto
- Relatórios formatados



SnpEff / SnpSift

Definição: Suite para anotação funcional (SnpEff) e filtragem (SnpSift) de VCFs.

Uso comum: Padrão em pipelines Galaxy. SnpSift dbNSFP adiciona anotações de gnomAD, REVEL, AlphaMissense, SpliceAI, CADD e ClinVar em um único passo.



SIFT (Sorting Intolerant From Tolerant)

Definição: Prediz impacto de substituições de aminoácidos.

Nota: Uso isolado **desencorajado** desde Pejaver 2022 — considerar via meta-preditores.



PolyPhen-2

Definição: Prediz se variação de aminoácido afeta estrutura/função proteica.

Nota: Uso isolado **desencorajado** — recomendação atual é usar REVEL ou AlphaMissense.



CADD Score

Definição: Score integrado predizendo **deleteriedade** de variantes.

Escala: 0-40+ (scores maiores = mais deletério)

Threshold: CADD >15 é **threshold antigo e não recomendado isoladamente**. Substituído por preditores calibrados (REVEL, AlphaMissense) segundo Pejaver 2022.



REVEL (Rare Exome Variant Ensemble Learner)

Definição: Meta-preditor de patogenicidade para variantes missense.

Calibração ClinGen: PP3 a partir de 0,644; PP3_Strong $\geq$ 0,932 (Pejaver 2022).

Status: Recomendado como **primeira escolha** para PP3/BP4 missense.



AlphaMissense

Definição: Preditor de missense do DeepMind (Cheng et al., Science, 2023).

Cobertura: 71 milhões de variantes missense possíveis pré-computadas.

Adoção: Sendo integrado às diretrizes ClinGen; complemento a REVEL.



SpliceAI

Definição: Rede neural para predição de impacto em splicing (Jaganathan et al., Cell, 2019).

Calibração: Delta $\geq$ 0,20 sugere impacto; $\geq$ 0,50 evidência forte (Walker et al. 2023).

Uso ACMG: Padrão para critérios PP3/BP4 de splicing.



ClinVar

Definição: Base de dados de variantes com **interpretação clínica** (NCBI).

Sistema de estrelas:

- 0★: sem critérios de classificação
- 1★: critérios sem discordância
- 2★: múltiplos submitters concordantes
- 3★: revisão por expert panel (ClinGen VCEP)
- 4★: guideline de prática clínica

Nota ACMG: Apenas classificações 2★+ satisfazem os critérios PP5/BP6.

URL: clinvar.ncbi.nlm.nih.gov



gnomAD v4 (Genome Aggregation Database)

Definição: Base de dados de **frequências alélicas** em populações não-selecionadas para doença.

Importância: Essencial para distinguir variantes raras vs. benignas — referência para critérios PM2 e BA1/BS1.

Cobertura atual (v4, novembro 2023): 807.162 indivíduos = 730.947 exomas + 76.215 genomas, alinhados em GRCh38.



OMIM (Online Mendelian Inheritance in Man)

Definição: Catálogo de genes humanos e herança genética mendeliana.

Conteúdo:

- Genes
- Fenótipos
- Herança
- Referências da literatura

URL: omim.org



dbSNP

Definição: Base de dados de **polimorfismos nucleotídicos únicos** (SNPs).

Nota: Útil para nomenclatura (rsIDs). Frequências populacionais devem ser lidas do **gnomAD**, não do dbSNP.



HGMD (Human Gene Mutation Database)

Definição: Base de dados de **mutações causadoras de doenças**.

Características:

- Mutações conhecidas patogênicas
- Referências completas
- Dados clínicos associados

Cautela: Versão pública está desatualizada; versão profissional (paga) categoriza como 'DM' variantes já reclassificadas em ClinVar.



HPO (Human Phenotype Ontology)

Definição: Ontologia padronizada de **fenótipos humanos**.

Uso: Ferramentas de priorização (Exomiser, Franklin, LIRICAL) usam termos HPO do paciente para calcular semelhança fenótipo-gene.

URL: hpo.jax.org



PubMed

Definição: Base de dados de literatura biomédica.

Uso: Validação de variantes → evidência na literatura.

URL: pubmed.ncbi.nlm.nih.gov



9. FERRAMENTAS DE ANÁLISE



Exomiser

Definição: Ferramenta de **priorização de variantes**.

Características:

- Modelos de herança (autossômica, X-ligada, etc.)
- Fenótipos HPO
- Dados de frequência populacional
- Predição funcional

Força: Integra múltiplas fontes → priorização acurada.



LIRICAL

Definição: Alternativa moderna ao Exomiser, com abordagem **likelihood-ratio**.

Vantagem: Mais transparente na justificativa das priorizações.



IGV (Integrative Genomics Viewer)

Definição: Visualizador de dados genômicos.

Permite:

- Inspeção manual de alinhamentos
- Visualização de variantes
- Validação visual de chamadas

Essencial: Para confirmação de achados clínicos.



Franklin (Genoox)

Definição: Plataforma de **interpretação clínica integrada**.

Características:

- Múltiplas bases de dados
- Interpretação ACMG automatizada

- Calibração ClinGen implementada
- Relatórios clínicos

Uso acadêmico: Gratuito para uso acadêmico.

VarSome

Definição: Base de dados online com **interpretação clínica integrada**.

Acesso: Interface web interativa

Dados: Integra ClinVar, OMIM, gnomAD, REVEL, AlphaMissense, SpliceAI, etc.

InterVar

Definição: Ferramenta **automatizada** para interpretação segundo critérios ACMG.

Vantagem: Padronização de classificação.

Cautela: Interpretação preliminar; requer curadoria manual.

MARRVEL

Definição: Integração de múltiplos recursos genômicos.

Função: Análise de genes candidatos.

Dados: Variantes, expressão, interações proteicas, ortólogos em organismos-modelo.

PVS1 Calculator

Definição: Ferramenta auxiliar na avaliação de critério **PVS1**.

Implementa: Árvore de decisão de Abou Tayoun et al. (2018) — modula PVS1, PVS1_Strong, PVS1_Moderate, PVS1_Supporting.

Galaxy Project

Definição: Ambiente bioinformático baseado em navegador para reprodutibilidade.

Uso didático: Padrão em ensino de pipelines WES (BWA-MEM, FreeBayes, SnpEff).

URL: usegalaxy.org



10. GENOMAS DE REFERÊNCIA

hg38 (GRCh38)

Definição: Montagem **atual** de referência do genoma humano.

Versão: Genome Reference Consortium Human Build 38

Lançamento: 2013

Status: Padrão-ouro para análise WES/WGS clínica. Base do gnomAD v4, ClinVar atual e VCEPs do ClinGen.

hg19 (GRCh37)

Definição: Montagem anterior de referência.

Status: Legacy (em desuso)

Uso: Ainda encontrado em bancos e artigos antigos. Requer liftover para GRCh38.



T2T-CHM13 (T2T-CHM13v2.0)

Definição: Primeira montagem completa (telômero-a-telômero) do genoma humano.

Lançamento: 2022 (Nurk et al., Science)

Melhorias: Preencheu ~200 Mb ausentes em GRCh38 — centrômeros, DNA satélite, rDNA, cromossomo Y completo.

Status atual: Adoção progressiva; GRCh38 continua sendo o padrão em uso clínico corrente.

Nota: Não existe GRCh39 — a próxima grande atualização é o T2T-CHM13.



Liftover

Definição: Processo de **conversão de coordenadas** genômicas entre versões diferentes.

Importância: Compatibilidade entre diferentes análises e bancos de dados.

Ferramentas: UCSC LiftOver, CrossMap, `bcftools +liftover`

Nota: Taxa de falha típica GRCh37→GRCh38 é ~0,3% das variantes — deve ser reportada.



11. ESTRUTURA E INTERPRETAÇÃO DE ARQUIVO VCF

O VCF é um arquivo texto tab-delimitado dividido em duas partes principais: **Cabeçalho (metadados)** e **Linhas de Dados (registros de variantes)**.



Cabeçalho (Metadados)

- Inicia com linhas `##`
- Contém: versão do VCF, genoma de referência (ex: GRCh38), data de criação, definições de campos (INFO/FORMAT/FILTER)
- Exemplo: `##INFO=<ID=DP,Number=1,Type=Integer,Description="Total Depth">`



Linhas de Dados (Registros de Variantes)

Estrutura: Cada linha representa uma variante detectada. Colunas obrigatórias:

Nº	Nome	Descrição
1	CHROM	Cromossomo onde a variante está localizada (ex: chr1, chrX)
2	POS	Posição inicial da variante no cromossomo
3	ID	Identificador público (ex: rsID para SNPs conhecidos ou '.' se desconhecido)
4	REF	Nucleotídeo(s) de referência (alelo)

		selvagem)
5	ALT	Nucleotídeo(s) alternativo(s) (variante) encontrado(s)
6	QUAL	Score de qualidade da chamada da variante
7	FILTER	Status do filtro do pipeline (ex: PASS, LowQual)
8	INFO	Metadados e anotações sobre a variante
9	FORMAT	Códigos que definem a ordem dos dados em SAMPLE (ex: GT:AD:DP:GQ:PL)
10+	SAMPLE(S)	Dados genotípicos específicos do(s) paciente(s)

Nota: Se VCF for de trio, haverá três colunas SAMPLE (probando, mãe, pai).



Importância para Filtragem e Interpretação



Filtragem Inicial:

- **FILTER:** Apenas variantes com PASS seguem para análise
- **INFO/AF:** Variantes comuns (AF >1% em gnomAD) geralmente excluídas
- **INFO/consequence:** Priorização por impacto (high > moderate > low)



Interpretação Genotípica e Clínica:

- **FORMAT/GT:** Informa se a variante é homozigota (1/1), heterozigota (0/1), de novo, etc.
- **FORMAT/DP, AD:** Avalia profundidade e distribuição de reads; calcula VAF (crítico em somático e mosaïcismo)
- **VAF (Variant Allele Frequency):** $AD_ALT / (AD_REF + AD_ALT)$. Germline heterozigoto $\approx 0,5$; VAF intermediária sugere mosaïcismo/contaminação
- **Trio:** Comparação de GT entre paciente e pais identifica variantes de novo (Critério **PS2** ACMG)



Resumo

O VCF é mais que um relatório — é uma base estruturada essencial para filtragem, priorização, interpretação clínica e emissão de laudos confiáveis. As colunas INFO e SAMPLE são estratégicas para integrar critérios ACMG/AMP e ferramentas automáticas.



12. TIPOS DE VARIANTES E CLASSIFICAÇÃO FUNCIONAL

Esta seção foca nas categorias de variantes mais relevantes no diagnóstico molecular, especialmente aquelas com maior impacto clínico: **missense**, **nonsense**, **frameshift** e **variantes de splice site**.

Tipo	Ícone	Definição	Efeito	Exemplo	ACMG
Missense		Substituição de	Pode alterar	BRCA1/2, FGFR3	P, LP, VUS

		nucleotídeo, alterando 1 aminoácido	função, estrutura ou estabilidade proteica	(acondroplasia)	
Nonsense	☠️	Mudança causa códon de parada prematuro; proteína truncada	Quase sempre resulta em perda de função, altamente patogênica	DMD (Duchenne), TP53 p.Arg213Ter	P, LP (PVS1)
Frameshift	🔥	Inserção/deleção altera quadro de leitura	Alteração massiva; gera proteína aberrante ou truncada	BRCA1, COL1A1 (osteogênese imperfeita)	P (PVS1)
Splice site canônico	🚦	Alteração $\pm 1/\pm 2$ do sítio de splicing	Provoca inclusão/exclusão de éxons, proteína defeituosa	MLH1, NF1, CFTR	P, LP (PVS1)
Splice region	🎵	Alteração ± 3 a ± 8 ou em ESE/ESS	Impacto variável; requer SpliceAI para avaliação	Variável	PP3/BP4 conforme SpliceAI
In-frame indel	🔄	Adiciona/remove aminoácidos sem shift	Depende de domínio funcional afetado	CFTR $\Delta F508$ (deleção de 3 pb)	P a VUS
Sinônima	🚫	Não altera o aminoácido	Geralmente neutra; splicing críptico raro	Ampla maioria	BP7 (se não altera splicing)



Interpretação Clínica/Funcional

- **Missense** (🌱): Impacto depende do resíduo afetado, relevância estrutural e predição por REVEL/AlphaMissense
- **Nonsense** (☠️): Critério ACMG PVS1 (probabilidade extrema se gene não tolera perda de função)
- **Frameshift** (🔥): Alto potencial patogênico por gerar proteínas aberrantes/truncadas; PVS1
- **Splice site** (🚦): PVS1 aplicado quando há evidência experimental ou de SpliceAI; variantes $\pm 1/\pm 2$ quase sempre relevantes
- **Sinônimas** (🚫): geralmente BP7, mas verificar impacto em splicing críptico



Classificação segundo ACMG/AMP

- **P (Patogênica)**: Forte evidência clínica/funcional e consistência populacional
- **LP (Provavelmente Patogênica)**: Evidência robusta, ausência ou raridade populacional (probabilidade >90%)

- **VUS (Significância Incerta)**: Dados insuficientes para afirmação clínica

Combina-se impacto funcional, evidências populacionais (gnomAD v4, ClinVar), predições in silico calibradas (REVEL, AlphaMissense, SpliceAI) e segregação familiar para classificação final.



13. LIMITAÇÕES DO WES — O QUE ELE NÃO DETECTA BEM

É essencial que clínico e bioinformata saibam o que o WES **não** detecta bem, para não interpretar um WES negativo como ausência de causa genética.



Variantes intrônicas profundas

Limitação: WES cobre ± 10 pb dos íntrons flanqueadores. Variantes intrônicas profundas que criam sítios de splicing crípticos (frequentemente em BRCA1, ATM, NF1, DMD) escapam completamente.

Alternativa: WGS ou sequenciamento de RNA (RNA-seq).



Variantes regulatórias

Limitação: Promotores, enhancers, silencers, 5'/3' UTR distantes não são capturados sistematicamente.

Alternativa: WGS.



CNVs pequenas

Limitação: Deleções e duplicações abaixo de ~50 pb têm sensibilidade limitada. Duplicações intragênicas em BRCA1, DMD, MECP2 podem passar despercebidas.

Alternativa: MLPA, aCGH ou análise de CNV específica em WES (ExomeDepth, GATK gCNV).



Rearranjos balanceados

Limitação: Translocações e inversões balanceadas não alteram sequência codificante — invisíveis ao WES.

Alternativa: Cariótipo, FISH, WGS de leitura longa.



Expansões de repetições

Limitação: Trinucleotídeos e outros repeats patogênicos (HTT, FMR1, DMPK, C9orf72) não são detectados em WES.

Alternativa: PCR triplet-primed, ExpansionHunter em WGS, sequenciamento longo.



Regiões refratárias tecnicamente

Limitação: Pseudogenes (SMN1/SMN2, CYP21A2, HBA), regiões altamente repetitivas, sequências GC-ricas extremas (>75% GC).

Alternativa: Testes específicos por locus (MLPA, PCR longo).



Metilação e imprinting

Limitação: Alterações epigenéticas (Prader-Willi, Beckwith-Wiedemann) são invisíveis ao sequenciamento tradicional.

Alternativa: MS-MLPA, sequenciamento de bissulfito.



Variantes mitocondriais em baixa heteroplasmia

Limitação: WES tipicamente sub-cobre o mtDNA; heteroplasmas abaixo de 20% raramente são chamadas com confiança.

Alternativa: Sequenciamento mitocondrial dirigido.



RESUMO DE TERMINOLOGIAS POR CATEGORIA

Categoria	Termos Principais
Estrutura Genômica	Gene, Exoma, Éxon, Íntron, UTR, Cromossomo
Sequenciamento	WES, WGS, NGS, Read, Coverage, Paired-end
Formatos	FASTQ, BAM, VCF, SAM, CRAM
Processamento	Alinhamento, GATK, DeepVariant, Variant Calling
Variantes	SNV, SNP, Indel, CNV, VUS, Genótipo
Interpretação	ACMG/AMP, ClinGen SVI, MAF, Segregação
Qualidade	QC, FastQC, MultiQC, PCR Duplicate, Coverage
Bancos de Dados	ClinVar, gnomAD v4, OMIM, dbSNP, HPO
Preditores	REVEL, AlphaMissense, SpliceAI, CADD
Ferramentas	Exomiser, IGV, VEP, Franklin, Galaxy, VarSome



REFERÊNCIAS RÁPIDAS

Conversão de Escalas: 1 Kb = 1.000 pb · 1 Mb = 1.000.000 pb · 1 Gb = 1.000.000.000 pb

Qualidade Phred (Escala Logarítmica): Q20 = 99% (1% erro) · Q30 = 99,9% (0,1% erro) · Q40 = 99,99% (0,01% erro)

Coverage Recomendado:

- Diagnóstico clínico WES: $\geq 100\times$ (95% do alvo a $\geq 20\times$)
- Pesquisa padrão: 30-50 $\times$
- Detecção de variantes raras / mosaïcismo: $> 100\times$
- Painel oncológico somático: $> 500\times$

MAF Thresholds (uso ACMG):

- $< 0,01\%$ = Ultra-rara (**PM2_Supporting**)
- 0,01-1% = Rara (potencialmente patogênica)
- 1-5% = Infrequente (**BS1** se $>$ esperado)
- $> 5\%$ = Comum (**BA1** stand-alone benigna)



NOTAS IMPORTANTES PARA PROFISSIONAIS

- ✓ **Integração de dados:** Nunca confie em uma única métrica/ferramenta. Integre múltiplas fontes

- ✓ **Contexto clínico:** Sempre considere fenótipo e história clínica (HPO estruturado)
- ✓ **Validação:** Variantes clínicas devem ser validadas (Sanger, MLPA, confirmação independente)
- ✓ **Atualização:** Bases de dados e interpretações são dinâmicas → revise periodicamente
- ✓ **Reclassificação:** 5-10% dos VUS são reclassificáveis a cada 2-3 anos — processo contínuo
- ✓ **Documentação:** Manter trilha auditável de decisões, critérios ACMG aplicados e versões consultadas



REFERÊNCIAS FUNDAMENTAIS

Richards S, et al. Standards and guidelines for the interpretation of sequence variants. *Genet Med* 2015;17(5):405-424. doi:10.1038/gim.2015.30

Tavtigian SV, et al. Modeling the ACMG/AMP variant classification guidelines as a Bayesian classification framework. *Genet Med* 2018;20(9):1054-1060.

Abou Tayoun AN, et al. Recommendations for interpreting the loss of function PVS1 ACMG/AMP variant criterion. *Hum Mutat* 2018;39(11):1517-1524.

Pejaver V, et al. Calibration of computational tools for missense variant pathogenicity classification and ClinGen recommendations for PP3/BP4 criteria. *Am J Hum Genet* 2022;109(12):2163-2177.

Walker LC, et al. Using the ACMG/AMP framework to capture evidence related to predicted and observed impact on RNA splicing. *Am J Hum Genet* 2023;110(7):1046-1067.

Chen S, et al. A genome-wide mutational constraint map quantified from variation in 76,156 human genomes. *Nature* 2024;625:92-100. [gnomAD v4]

Nurk S, et al. The complete sequence of a human genome. *Science* 2022;376(6588):44-53. [T2T-CHM13]